

เทคนิคการจำแนกภาพสำหรับการเกษตรที่แม่นยำในการระบุอ้อยและ มันสำปะหลังด้วย Sentinel-2

Image Classification Techniques for Precision Agriculture to Identify Sugarcane and Cassava with Sentinel-2

"กรุณาย้ายใส่ชื่อผู้แต่ง"

บทคัดย่อ

งานวิจัยนี้มุ่งเน้นการพัฒนาเทคนิคการเรียนรู้เชิงลึก (Deep Learning) สำหรับการจำแนกพื้นที่เพาะปลูกอ้อยและมันสำปะหลังด้วยภาพถ่ายดาวเทียม Sentinel-2 ที่มีความแม่นยำสูง โดยนำเทคนิค Convolutional Neural Networks (CNNs) มาใช้เพื่อสร้างโมเดลประมวลผลข้อมูลภาพถ่าย ซึ่งมีการทดลองเปรียบเทียบประสิทธิภาพของโมเดลต่างๆ ได้แก่ ResNet50v2, EfficientNetV2B0, DenseNet121 และ MobileNetV2 พร้อมทั้งปรับแต่งค่าพารามิเตอร์ เช่น Batch size, Epochs และการใช้ Data Augmentation เพื่อเพิ่มความหลากหลายของข้อมูล ผลการวิจัยพบว่าโมเดล ResNet50v2 มีประสิทธิภาพสูงที่สุดในการจำแนกภาพ ด้วยค่า Accuracy 98.23%, Precision 97.82%, Recall 97.81% และ Test Accuracy 95% การใช้ Data Augmentation มีบทบาทสำคัญในการเพิ่มความแม่นยำ นอกจากนี้ โมเดล MobileNetV2 มีจุดเด่นด้านความเร็วในการฝึก (Training Time) แม้จะมีข้อผิดพลาดเล็กน้อยในคลาสมันสำปะหลัง (Cassava) งานวิจัยนี้ชี้ให้เห็นถึงศักยภาพของ Deep Learning และ Sentinel-2 ในการสนับสนุนการเกษตรแบบแม่นยำ

คำสำคัญ – การเรียนรู้เชิงลึก, การจำแนกภาพ, Sentinel-2, การเกษตรแบบแม่นยำ, โครงข่ายประสาทเทียม

ABSTRACT

This research focuses on developing deep learning techniques for accurately classifying sugarcane and cassava cultivation areas using Sentinel-2 satellite imagery. Convolutional Neural Networks (CNNs) were employed to construct models for image data processing. The study compares the performance of various models, including ResNet50v2, EfficientNetV2B0, DenseNet121, and MobileNetV2, with parameter tuning for batch size, epochs, and data augmentation to enhance data diversity. The findings indicate that the ResNet50v2 model achieves the highest performance, with an accuracy of 98.23%, precision of 97.82%, recall of 97.81%, and test accuracy of 95%. Data augmentation significantly contributes to improving model accuracy. Additionally, the MobileNetV2 model demonstrates exceptional training speed, although it shows minor errors in the cassava class. This study highlights the potential of deep learning and Sentinel-2 satellite imagery in supporting precision agriculture.

Keywords – Deep Learning, Image Classification, Sentinel-2, Precision Agriculture, Convolutional Neural Networks

1. บทนำ

ในปี 2566-2567 จังหวัดบุรีรัมย์และสระแก้วเผชิญปัญหาภัยแล้งส่งผลต่อผลผลิตมันสำปะหลังและอ้อย แม้พื้นที่ปลูกมันสำปะหลังในบุรีรัมย์เพิ่มขึ้น แต่ผลผลิตลดลงเนื่องจากการเจริญเติบโตไม่เต็มที่ เกษตรกรปลูกพันธุ์ที่มีผลผลิตสูง เช่น ระยอง 72 และเกษตรศาสตร์ 50 ส่วนสระแก้วเป็นแหล่งปลูกมันสำปะหลังอันดับ 1 ของภาคตะวันออก แต่เนื้อที่และผลผลิตลดลงเพราะขาดแคลนท่อนพันธุ์และเปลี่ยนไปปลูกพืชอื่น [1]

ภาพถ่ายดาวเทียม Sentinel-2 ซึ่งเป็นส่วนหนึ่งของโครงการ Copernicus ของสหภาพยุโรป มีศักยภาพสูงในการสำรวจและเก็บข้อมูลภาพถ่ายความละเอียดสูงที่ครอบคลุมทั่วโลก โดย Sentinel-2 มีความสามารถในการเก็บภาพในแถบคลื่นความถี่หลายช่วง ทั้งในช่วงคลื่นที่มองเห็นได้ (Visible Light) และช่วงคลื่นอินฟราเรด (Infrared) ข้อมูลจากแถบคลื่นเหล่านี้มีความสำคัญในการวิเคราะห์สภาพแวดล้อมและพืชผล ทำให้สามารถจำแนกชนิดของพืชในพื้นที่เพาะปลูกได้อย่างแม่นยำมากขึ้น [2]

การวิเคราะห์ข้อมูลด้วยเทคโนโลยีปัญญาประดิษฐ์ (AI) การเรียนรู้เชิงลึก (Deep Learning) เป็นเทคนิคที่มีประสิทธิภาพสูง โดยเฉพาะอย่างยิ่งในด้านการจำแนกประเภทภาพ (Image Classification) [3] โมเดลแบบ Convolutional Neural Networks (CNNs) ได้ถูกพัฒนาขึ้นเพื่อเรียนรู้คุณลักษณะสำคัญของภาพ ทำให้สามารถแยกแยะความแตกต่างของพืชที่มีลักษณะทางกายภาพใกล้เคียงกัน [4]

งานวิจัยนี้ทำขึ้นเพื่อพัฒนาโมเดลการเรียนรู้เชิงลึก (Deep Learning) ที่สามารถจำแนกพื้นที่เพาะปลูกอ้อยและมันสำปะหลังจากภาพถ่ายดาวเทียม Sentinel-2 ได้อย่างแม่นยำ

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 ภาพถ่ายดาวเทียม Sentinel-2

ภาพถ่ายดาวเทียม Sentinel-2 เป็นข้อมูลภาพที่ได้รับจากดาวเทียม Sentinel-2 ซึ่งเป็นส่วนหนึ่งของโครงการ Copernicus ของสหภาพยุโรป ดำเนินการโดย European Space Agency (ESA) ดาวเทียม Sentinel-2 ออกแบบมาเพื่อการสังเกตการณ์โลก (Earth Observation) โดยเฉพาะ โดยให้ข้อมูลที่มีประโยชน์ในหลากหลายด้าน เช่น การเกษตร การจัดการทรัพยากรธรรมชาติ และการเฝ้าระวังสิ่งแวดล้อม [2]

ภายในงานวิจัยนี้ได้ใช้ภาพถ่ายดาวเทียม Sentinel-2 เป็น Data set ที่ใช้ในการสำหรับการเรียนรู้ (Train) และข้อมูลสำหรับทดสอบ (Test)

2.2 การเรียนรู้เชิงลึก (Deep Learning)

การเรียนรู้เชิงลึก (Deep Learning) หรือการเรียนรู้เชิงลึกเป็นการพัฒนาให้เครื่องจักรหรือคอมพิวเตอร์สามารถเลียนแบบการทำงานของระบบโครงข่ายประสาท (Neurons) เหมือนกับสมองมนุษย์เรียกว่าโครงข่ายประสาทเทียม (Neural Network: NN) โดย Deep Learning ถูกสร้างขึ้นจากการนำ NN หลายๆ Layer มาใช้วิเคราะห์และหาคำตอบซึ่งคำว่า Deep Learning ก็มาจากการใช้ NN มากกว่า 2 Layer เพื่อให้เครื่องจักรเรียนรู้และสร้างแบบจำลองจึงเปรียบเทียบได้ว่า Layer ของ NN ถูกใช้จำนวนมากสำหรับขั้นตอนการประมวลผลทำให้มีโครงสร้างการเรียนรู้ที่ลึก (Deep) ยิ่งขึ้นโดยวิธีการเรียนรู้ของเครื่องจักรแบบ Deep Learning ถูกเสนอหลายแบบเช่นโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) [3]

2.3 โครงข่ายประสาทเทียมแบบคอนโวลูชัน

โครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) เป็นโครงสร้างของโครงข่ายประสาทเทียมที่ได้รับการออกแบบมาเฉพาะสำหรับการประมวลผลข้อมูลที่มีโครงสร้างเชิงพื้นที่ เช่น ภาพถ่าย วิดีโอ หรือข้อมูลอื่นที่มีลักษณะเป็นตาราง โครงข่ายประเภทนี้ถูกใช้งานอย่างแพร่หลายในด้านต่างๆ เช่น การจำแนกรูปภาพ (Image Classification) การตรวจจับวัตถุ (Object Detection) และการแบ่งส่วนภาพ (Image Segmentation) [4]

ภายในงานวิจัยนี้ได้ใช้โครงข่ายประสาทเทียมแบบคอนโวลูชันทั้งหมด 4 โมเดล ได้แก่ ResNet50v2, DenseNet121, EfficientNetV2B0 และ MobileNetV2

2.4 MobileNetV2

MobileNetV2 เป็นโมเดลที่มีประสิทธิภาพและมีน้ำหนักเบาสำหรับงานจำแนกภาพ สถาปัตยกรรมที่มีประสิทธิภาพเมื่อรวมกับความสามารถในการรักษาความแม่นยำสูง ทำให้เป็นตัวเลือกที่เหมาะสมสำหรับอุปกรณ์ที่มีทรัพยากรจำกัด ด้วยการทำความเข้าใจคุณสมบัติหลัก สถาปัตยกรรม กระบวนการฝึกอบรม การประเมินประสิทธิภาพ และการนำ MobileNet-v2 ไปใช้ นักพัฒนาและนักวิจัยสามารถใช้ประโยชน์จากความสามารถของ

มันเพื่อแก้ปัญหาการจำแนกภาพในโลกแห่งความเป็นจริงได้อย่างมีประสิทธิภาพ [5]

2.5 การประเมินประสิทธิภาพของโมเดล

การประเมินประสิทธิภาพของโมเดลใช้วิธีการสุ่มเลือกข้อมูลสำหรับการเรียนรู้ (Train) และข้อมูลสำหรับทดสอบ (Test) การวัดประสิทธิภาพพิจารณาจากค่าความถูกต้องของการทำนายผลทั้งหมดของโมเดล (Accuracy) ดังสมการที่ 1 ค่าความถูกต้องของประเด็นที่โมเดลสนใจที่จะทำนาย (Precision) ดังสมการที่ 2 และค่าสัดส่วนที่โมเดลสามารถทำนายประเด็นที่เราสนใจทั้งหมด (Recall) ดังสมการที่ 3 ในการจำแนกกลุ่มข้อมูลซึ่งเป็นค่าที่ได้จากวิธีการทดสอบโมเดลเพื่อหาค่าพยากรณ์ความถูกต้องของข้อมูลต่อจำนวนข้อมูลทั้งหมดโดยใช้สมการดังนี้ [6]

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (1)$$

$$Precision = \frac{TP}{(TP + FP)} \quad (2)$$

$$Recall = \frac{TP}{(TP + FN)} \quad (3)$$

โดย True Positive (TP) คือ โมเดลทำนายว่า ใช่ และคำตอบจริงๆ ก็คือ ใช่

False Positive (FP) คือ โมเดลทำนายว่า ใช่ แต่คำตอบจริงๆ คือ ไม่ใช่

False Negative (FN) คือ โมเดลทำนายว่า ไม่ใช่ แต่คำตอบจริงๆ คือ ใช่

True Negative (TN) คือ โมเดลทำนายว่า ไม่ใช่ และคำตอบจริงๆ ก็คือ ไม่ใช่

โดยภายในงานวิจัยนี้ได้ใช้การประเมินประสิทธิภาพของโมเดลในการหาค่า Accuracy, Precision และ Recall เพื่อวัดหาค่าประสิทธิภาพของโมเดล

2.6 Learning Curve

Learning Curve คือกราฟที่แสดงความสัมพันธ์ระหว่างผลลัพธ์ (เช่น ความแม่นยำหรือประสิทธิภาพ) กับจำนวนประสบการณ์หรือเวลาที่ใช้ในการฝึกฝนหรือเรียนรู้ใน Deep Learning โดยใช้วิเคราะห์พัฒนาการของโมเดล เช่น การปรับปรุงความแม่นยำจากชุดข้อมูลฝึก (Training) และชุดข้อมูล

ตรวจสอบ (Validation) ซึ่งกราฟสามารถแสดงถึงปัญหา Underfitting (ผลลัพธ์ต่ำทั้ง Training และ Validation) หรือ Overfitting (Training แม่นยำสูงแต่ Validation ต่ำ) และช่วยวิเคราะห์เพื่อปรับกระบวนการฝึกให้โมเดลมีประสิทธิภาพสูงสุด (Optimal Learning) [7]

โดยภายในงานวิจัยนี้ได้ใช้ Learning Curve เพื่อดูการไหลของข้อมูลการเรียนรู้ (Train) ในโมเดลนั้น ๆ

2.7 Confusion Matrix

Confusion Matrix คือเมตริกที่ใช้ในการประเมินผลของโมเดลการจำแนกประเภท โดยแสดงการทำนายของโมเดลเทียบกับค่าจริงในรูปแบบตาราง ซึ่งประกอบด้วย 4 ส่วนหลัก ได้แก่ True Positive (TP), True Negative (TN), False Positive (FP) และ False Negative (FN) ซึ่งช่วยในการคำนวณค่าชี้วัดสำคัญ เช่น Accuracy, Precision และ Recall เพื่อประเมินประสิทธิภาพของโมเดล โดยเฉพาะในการจัดการกับปัญหาคลาสไม่สมดุล (Imbalanced Classes) และช่วยให้เห็นภาพรวมการทำนายในแต่ละคลาสได้ชัดเจน ใน Python สามารถใช้ฟังก์ชัน confusion_matrix จากไลบรารี sklearn ในการสร้างได้ง่าย ๆ [8]

โดยภายในงานวิจัยนี้ได้ใช้ Confusion Matrix เพื่อดูผลการทดสอบ (Test) ในโมเดลนั้น ๆ

2.8 ภาษาไพทอน (Python)

ภาษาไพทอน (Python) เป็นภาษาโปรแกรมคอมพิวเตอร์ระดับสูงที่รูปแบบการเขียนโปรแกรมมีความกระชับรัด อ่านง่าย มีความซับซ้อนโครงสร้าง และไวยากรณ์ของภาษาน้อยมีการทำงาน Interpreter คือการแปลชุดคำสั่งที่ละบรรทัดเพื่อป้อนเข้าสู่หน่วยประมวลผลให้คอมพิวเตอร์ทำงานตามที่ต้องการ ประกอบด้วยเนื้อหาได้แก่ (1) รู้จักไพทอน ตัวแปร ชนิดข้อมูล (2) การแสดงผลและการรับค่าในภาษาไพทอน (3) นิพจน์และตัวดำเนินการ (4) การเขียนโปรแกรมภาษาไพทอนแบบมีเงื่อนไข (5) การเขียนโปรแกรมภาษาไพทอนแบบทำซ้ำ [9]

โดยภายในงานวิจัยนี้ได้ใช้ภาษาไพทอน เพื่อเขียนโค้ดดึงภาพถ่ายจากดาวเทียม Sentinel-2 เพื่อสร้างโมเดลสำหรับการจำแนกอ้อยและมันสำปะหลัง

2.9 Google Colaboratory

Google Colaboratory ซึ่งเป็น Jupyter Notebook บนคลาวด์ที่ Google ให้บริการฟรี มีคุณสมบัติเด่น เช่น ความเป็น

คลาวด์ อินเทอร์เน็ตที่ใช้งานง่าย รองรับ GPU และ TPU และการทำงานร่วมกับ Google Cloud Platform (GCP) เหมาะสำหรับนักวิทยาศาสตร์ข้อมูลและนักพัฒนาซอฟต์แวร์ บทนี้ยังสอนการสร้างและใช้งาน Colab Notebook ตั้งแต่การสร้างสมุดบันทึก การตั้งค่า Runtime การเขียนโค้ด Python ไปจนถึงการสร้างภาพข้อมูลด้วย Matplotlib และ Seaborn และการทำงานกับข้อมูลจาก Google Drive รวมถึงการใช้ไลบรารี TensorFlow, Keras และ scikit-learn ในการสร้างโมเดล Machine Learning [10]

โดยภายในงานวิจัยนี้ได้ใช้ Google Colaboratory เพื่อเขียนโค้ดดึงภาพถ่ายจากดาวเทียม Sentinel-2 และเพื่อสร้างโมเดลสำหรับการจำแนกอ้อยและมันสำปะหลังด้วยภาษาไพทอน

3. ขั้นตอนการดำเนินงานวิจัย

3.1 การเก็บรวบรวมข้อมูล

ภายในวิจัยได้ทำการเก็บรวบรวมพิกัดของพื้นที่เพาะปลูกอ้อยและมันสำปะหลังที่แน่นอนรวมทั้ง 2 พื้นที่ประมาณ 40 ตำแหน่ง เพื่อทำการเขียนโค้ดด้วยภาษาไพทอน (Python) ใน Google Colaboratory เพื่อทำการดึงภาพจากดาวเทียม Sentinel-2

3.2 การเตรียมข้อมูลเบื้องต้น

เมื่อได้ภาพถ่ายจากดาวเทียม Sentinel-2 จากพิกัดที่รวบรวมมาแล้ว ภายในวิจัยได้ทำการเขียนโค้ดกรองปริมาณเมฆจากพิกัดภาพถ่ายที่ดึงมา เพื่อให้สะดวกในการลบภาพถ่ายที่ไม่ต้องการทิ้ง ซึ่งได้ภาพถ่ายของพื้นที่เพาะปลูกอ้อยและมันสำปะหลัง แบ่งเป็นคลาสละ 600 ภาพ รวมทั้งหมด 1200 ภาพที่ใช้เป็น Data set สำหรับการพัฒนาโมเดลดังภาพ 1



ภาพ 1 ตัวอย่างภาพถ่ายดาวเทียม Sentinel-2 ก) พื้นที่ปลูกอ้อย ข) พื้นที่ปลูกมันสำปะหลัง

3.3 การพัฒนาโมเดล

การใช้ Deep Learning ร่วมกับ Convolutional Neural Networks (CNNs) สำหรับการจำแนกพื้นที่เพาะปลูกอ้อยและมันสำปะหลัง และวัดค่าประสิทธิภาพของโมเดลที่ใช้

3.3.1 การสร้างชุดข้อมูล

เมื่อได้ภาพถ่ายคลาสละ 600 ภาพ แล้วทำได้แบ่งชุดการเรียนรู้ (Train) คลาสละ 480 ภาพและสำหรับชุดทดสอบ (Test) คลาสละ 120 ภาพ โดยจะแบ่งเป็น 80 : 20 เพื่อทำการทดสอบหาค่า Accuracy, Precision และ Recall

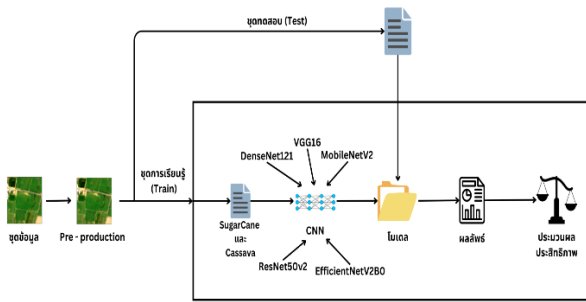
3.3.2 การเลือกใช้โมเดลสำหรับการเรียนรู้ (Train) และสำหรับการทดสอบ (Test)

ขั้นตอนนี้จะเป็นการสร้างโมเดลแบบจำลองโดยการประยุกต์ใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) ผ่านโครงข่ายประสาทเทียม (Convolutional Neural Networks: CNNs) โดยการทำงานแบ่งเป็น 3 ขั้นตอน ได้แก่

1) การแบ่งชุดข้อมูลภาพถ่ายดาวเทียม โดยขั้นตอนนี้เป็นการนำข้อมูลที่เตรียมไว้สำหรับการสร้างโมเดล โดยทำการแบ่งชุดข้อมูลออกเป็นหมวดหมู่ตามประเภทของพื้นที่เพาะปลูกอ้อยและมันสำปะหลัง ซึ่งจะช่วยให้โมเดลสามารถเรียนรู้ลักษณะเฉพาะของพื้นที่แต่ละประเภทได้อย่างแม่นยำ

2) การเลือกใช้อัลกอริทึมสำหรับการจำแนกภาพส่งผลกระทบต่อประสิทธิภาพของโมเดล โดยขึ้นอยู่กับลักษณะข้อมูลและทรัพยากรที่ใช้ ได้เลือกอัลกอริทึมที่ใช้สำหรับการทดสอบ ได้แก่ ResNet50v2 ซึ่งช่วยลดปัญหา Gradient สูญหายและเหมาะกับข้อมูลซับซ้อน EfficientNetV2B0 ที่มีความสมดุลระหว่างความแม่นยำและความเร็ว DenseNet121 ที่ลดพารามิเตอร์และแก้ปัญหา Overfitting และ MobileNetV2 ซึ่งเน้นการประมวลผลเร็วและใช้ทรัพยากรน้อย นี่คือการเลือกอัลกอริทึมที่ได้ทำการทดสอบเพื่อหาโมเดลที่ได้ค่าความแม่นยำสูงสุด

3) ชุดการเรียนรู้ (Train) และชุดทดสอบ (Test) สำหรับการพัฒนาโมเดลการเรียนรู้เชิงลึก โดยการแบ่งข้อมูลออกเป็น 2 ชุด ได้แก่ ชุดการเรียนรู้ (Train) 80% และชุดทดสอบ (Test) 20% ชุดการเรียนรู้จะถูกใช้ในการสร้างโมเดล และชุดข้อมูลทดสอบจะถูกนำมาใช้ในการประเมินความสามารถของโมเดลผ่านการวัด Accuracy, Precision และ Recall ของการจำแนกพื้นที่ปลูกอ้อยและมันสำปะหลังดังภาพ 2



ภาพ 2 การพัฒนาโมเดลการเรียนรู้เชิงลึก

4. ผลลัพธ์

การฝึกฝนและการประเมินผลของโมเดลการเรียนรู้เชิงลึกหลายตัว (CNNs) ได้แก่ ResNet50v2, EfficientNetV2B0, DenseNet121 และ MobileNetV2 โดยการทดลองมีการปรับแต่งค่าพารามิเตอร์ต่างๆ มี ขนาดแบทช์ (Batch size) จำนวนรอบการฝึก (Epochs) 5-Fold Cross-Validation (5CV) การขยายข้อมูล (Data Augmentation) และค่าอัตราการเรียนรู้ (Learning Rate) โดยใช้ Optimizer แบบ Adam ที่อัตราการเรียนรู้ 0.001 และ Loss Function เป็น categorical crossentropy ผลลัพธ์ที่ได้จากการทดสอบในชุดข้อมูลทดสอบประกอบด้วยค่า Accuracy, Precision และ Recall ซึ่งช่วยในการประเมินประสิทธิภาพของแต่ละโมเดลและการเลือกโมเดลที่เหมาะสมที่สุดสำหรับการใช้งาน

4.1 การปรับแต่งค่าพารามิเตอร์ต่างๆ

1) ขนาดแบทช์ (Batch size) หมายถึง จำนวนตัวอย่าง (samples) หรือข้อมูลที่ถูกนำไปประมวลผลพร้อมกันในแต่ละรอบ (iteration) ของการฝึกฝนโมเดลในกระบวนการเรียนรู้เชิงลึก (Deep Learning) โดยในระหว่างการฝึกฝนโมเดล ข้อมูลจะถูกแบ่งออกเป็นหลายๆ แบทช์เพื่อให้ง่ายต่อการคำนวณและอัปเดตน้ำหนัก (weights) ของโมเดลในแต่ละรอบ

2) จำนวนรอบการฝึก (Epochs) หมายถึง จำนวนครั้งที่โมเดลจะทำการฝึกฝนโดยใช้ชุดข้อมูลทั้งหมด (training data) ในระหว่างการฝึกโมเดลหนึ่งครั้ง (หนึ่ง Epoch) โมเดลจะเรียนรู้จากข้อมูลที่มีทั้งหมด และการฝึกฝนจะทำซ้ำหลายๆ รอบเพื่อปรับปรุงประสิทธิภาพของโมเดล

3) การขยายข้อมูล (Data Augmentation : DA) เป็นเทคนิคที่ใช้ในการเพิ่มจำนวนข้อมูลฝึก (training data) โดยการสร้างตัวอย่างใหม่จากข้อมูลเดิมผ่านการเปลี่ยนแปลงลักษณะของ

ข้อมูล เช่น การหมุน, การพลิก, การยืดหด, การปรับความสว่าง หรือการเพิ่มเสียงรบกวน เทคนิคนี้ช่วยให้โมเดลเรียนรู้ลักษณะที่หลากหลายของข้อมูลมากขึ้น และสามารถลดการโอเวอร์ฟิต (overfitting) ได้ เนื่องจากข้อมูลที่หลากหลายจะช่วยให้โมเดลทั่วไปได้ดีขึ้นในกรณีที่มีข้อมูลไม่มากพอ การขยายข้อมูลมักถูกนำไปใช้ในงานที่เกี่ยวกับการประมวลผลภาพ เช่น การจำแนกภาพ หรือการตรวจจับวัตถุ ซึ่งผู้วิจัยได้ใช้ Data Augmentation ดังนี้

- (1) rotation_range=30: หมุนภาพได้สูงสุด 30 องศาในทิศทางใดก็ได้ (ทั้งทิศทางเข็มนาฬิกาและทวนเข็มนาฬิกา) เพื่อเพิ่มความหลากหลายให้กับภาพที่ใช้ฝึกฝน
- (2) width_shift_range=0.1: เลื่อนภาพในแนวนอน (ซ้าย/ขวา) โดยมีค่าเลื่อนสูงสุด 10% ของขนาดภาพ
- (3) height_shift_range=0.1: เลื่อนภาพในแนวตั้ง (บน/ล่าง) โดยมีค่าเลื่อนสูงสุด 10% ของขนาดภาพ
- (4) shear_range=0.1: เปลี่ยนแปลงลักษณะการบิด (shearing) ของภาพในแนวเฉียง โดยมีค่าสูงสุด 0.1
- (5) zoom_range=0.1: ขยาย-ย่อจากภาพ โดยมีค่า zoom สูงสุด 10% (ทั้งขยายและย่อ)
- (6) horizontal_flip=True: พลิกภาพในแนวนอน (ซ้าย/ขวา)
- (7) vertical_flip=True: พลิกภาพในแนวตั้ง (บน/ล่าง)
- (8) brightness_range=[0.9, 1.1]: ปรับความสว่างของภาพในช่วง 90% ถึง 110% ของความสว่างเดิม เพื่อให้ภาพมีความสว่างเพิ่มขึ้นหรือลดลงเล็กน้อย
- (9) fill_mode='reflect': กำหนดวิธีการเติมพื้นที่ที่หายไปหลังการปรับแต่งภาพ (เช่น การหมุนหรือเลื่อนภาพ) ด้วยการสะท้อนขอบภาพที่มีอยู่
- (10) rescale=1./255: ปรับค่าสีในภาพจาก 0-255 (ช่วงสีของภาพเดิม) ให้มาอยู่ในช่วง 0-1 โดยการหารค่าด้วย 255 (เป็นการปกติค่าของพิกเซลก่อนส่งไปให้โมเดล) ตัวอย่างดังภาพ 3



ภาพ 3 ตัวอย่างภาพการขยายข้อมูล (Data Augmentation)

5) ค่าอัตราการเรียนรู้ (Learning Rate) คือ พารามิเตอร์สำคัญที่ควบคุมขนาดของการปรับค่าในแต่ละขั้นตอนของการฝึกโมเดลในการเรียนรู้เชิงลึกหรือการเรียนรู้เครื่อง (Machine Learning) เมื่อโมเดลทำการปรับค่าพารามิเตอร์ (เช่น น้ำหนักของโครงข่ายประสาท) ในแต่ละขั้นตอนการฝึกฝน การกำหนดค่าอัตราการเรียนรู้ที่เหมาะสมจะช่วยให้การฝึกฝนเป็นไปอย่างมีประสิทธิภาพ

6) Optimizer แบบ Adam ที่อัตราการเรียนรู้ 0.001 และ Loss Function เป็น Categorical Crossentropy ใช้ในการฝึกโมเดลการเรียนรู้เชิงลึกสำหรับปัญหาการจำแนกประเภทหลายคลาส (Multiclass classification) โดย Adam เป็น optimizer ที่ปรับการอัปเดตพารามิเตอร์โดยอัตโนมัติตาม momentum และ adaptive learning rate ซึ่งช่วยให้การฝึกมีประสิทธิภาพและรวดเร็วขึ้น ส่วน Categorical Crossentropy ใช้คำนวณความแตกต่างระหว่างค่าที่ทำนายและค่าจริงของแต่ละคลาสโดยใช้สูตรทางคณิตศาสตร์เพื่อให้โมเดลสามารถจำแนกประเภทข้อมูลได้อย่างแม่นยำ

4.2 ผลลัพธ์การเรียนรู้ (Train) และการทดสอบ (Test)

4.2.1 ResNet50v2


ผลลัพธ์การทดลองของการเรียนรู้ (Train) โมเดล ResNet50v2 ดังตาราง 1

ตาราง 1 ผลการทดลองของ ResNet50v2

Batch size	Epochs	Data Augmentation	Accuracy %	Precision %	Recall %	Time Train
-	50	No	98.44	93.11	90.94	20min 23s
32	50	No	98.85	96.80	95.94	13min 13s
64	50	No	98.13	96.27	95.94	13min 41s
64	100	No	99.06	94.33	93.33	23min 40s
-	50	Yes	97.60	97.12	97.08	15min 35s
32	50	Yes	98.23	97.63	97.60	12min 45s
64	50	Yes	96.35	95.88	95.83	12min 34s
-	100	Yes	97.81	97.67	97.60	25min 53s
32	100	Yes	98.13	97.84	97.81	22min 45s
64	100	Yes	96.67	95.77	95.73	21min 56s
-	200	Yes	98.23	97.93	97.92	45min 53s
32	200	Yes	98.23	97.82	97.81	42min 25s

ผลลัพธ์ที่ดีที่สุด คือ ใช้ Batch size 32, 5cv, 200 Epochs และ Data Augmentation ให้ค่า Accuracy, Precision, Recall และ Test เป็น 98.23%, 97.82%, 97.81% และ 95% ตามลำดับ

Learning Curve ผลลัพธ์ของการเรียนรู้ (Train) ของ ResNet50v2 ที่ดีที่สุดดังภาพ 4




ภาพ 4 Learning Curve ที่ดีที่สุดของ ResNet50v2

ผลลัพธ์การทดลองของการทดสอบ (Test) โมเดล ResNet50v2 ดังตาราง 2

ตาราง 2 ผลการทดลองค่า Accuracy Test ของ ResNet50v2

Batch size	Epochs	Data Augmentation	Time Train	Accuracy Test
-	50	No	20min 23s	40%
32	50	No	13min 13s	45%
64	50	No	13min 41s	47%
64	100	No	23min 40s	42%
-	50	Yes	15min 35s	93%
32	50	Yes	12min 45s	89%
64	50	Yes	12min 34s	97%
-	100	Yes	25min 53s	93%
32	100	Yes	22min 45s	95%
64	100	Yes	21min 56s	94%
-	200	Yes	45min 53s	89%
32	200	Yes	42min 25s	95%

Confusion Matrix ของโมเดลจำแนกประเภทสำหรับ Cassava และ SugarCane โดยโมเดลสามารถทำนาย SugarCane ได้ถูกต้องทั้งหมด 120 ครั้ง ไม่มีการทำนายผิด ในขณะที่ Cassava ทำนายถูกต้อง 109 ครั้ง และผิดเป็น SugarCane 11 ครั้ง แสดงว่าโมเดลมีความแม่นยำสูง ในคลาส SugarCane แต่ยังมีข้อผิดพลาดเล็กน้อยในคลาส Cassava ดังภาพ 5



ภาพ 5 Confusion Matrix การทดสอบ (Test) ResNet50v2 ที่ดีที่สุด

4.2.2 EfficientNetV2B0


ผลลัพธ์การทดลองของการเรียนรู้ (Train) โมเดล EfficientNetV2B0 ดังตาราง 3

ตาราง 3 ผลการทดลองของ EfficientNetV2B0

Batch size	Epochs	Data Augmentation	Accuracy %	Precision %	Recall %	Time Train
32	50	No	100	100	100	15min 47s
64	50	Yes	69.27	69.86	59.06	9min 15s
-	50	Yes	68.54	57.50	53.33	11min 30s
-	100	Yes	69.48	66.43	63.85	22min 50s
32	100	Yes	70.10	72.13	61.98	17min 57s

ผลลัพธ์ที่ดีที่สุด คือ ใช้ Batch size 32, 5cv, 100Epochs และ Data Augmentation ให้ค่า Accuracy, Precision, Recall และ Test เป็น 70.10%, 72.13%, 61.98% และ 63% ตามลำดับ

Learning Curve ผลลัพธ์ของการเรียนรู้ (Train) ของ EfficientNetV2B0 ที่ดีที่สุดดังภาพ 6




ภาพ 6 Learning Curve ที่ดีที่สุดของ EfficientNetV2B0

ผลลัพธ์การทดลองของการทดสอบ (Test) โมเดล EfficientNetV2B0 ดังตาราง 4

ตาราง 4 ผลการทดลองค่า Accuracy Test ของ EfficientNetV2B0

Batch size	Epochs	Data Augmentation	Time Train	Accuracy Test
32	50	No	15min 47s	50%
64	50	Yes	9min 15s	70%
-	50	Yes	11min 30s	62%
-	100	Yes	22min 50s	62%
32	100	Yes	17min 57s	68%

Confusion Matrix ของโมเดลจำแนกประเภทสำหรับ Cassava และ SugarCane โดยโมเดลสามารถทำนาย Cassava ได้ถูกต้องทั้งหมด 120 ครั้ง ไม่มีการทำนายผิดเป็น SugarCane ในขณะที่การทำนาย SugarCane มีความผิดพลาดสูง โดย SugarCane ถูกทำนายผิดเป็น Cassava ถึง 76 ครั้ง และทำนายถูกเพียง 44 ครั้ง แสดงว่าโมเดลมีประสิทธิภาพสูง ในคลาส Cassava แต่ยังต้องปรับปรุงในคลาส SugarCane ดังภาพ 7



ภาพ 7 Confusion Matrix การทดสอบ (Test) ที่ดีที่สุดของ EfficientNetV2B0

4.2.3 DenseNet121


ผลลัพธ์การทดลองของการเรียนรู้ (Train) โมเดล DenseNet121 ดังตาราง 5

ตาราง 5 ผลการทดลองของ DenseNet121

Batch size	Epochs	Data Augmentation	Accuracy	Precision	Recall	Time Train
-	50	No	99.90	99.69	99.69	21min 40s
32	50	No	99.79	99.69	99.69	17min 4s
-	50	Yes	98.65	98.27	98.23	21min 47s
32	50	Yes	98.65	98.36	98.33	21min 41s
-	100	Yes	99.06	98.66	98.65	37min 39s
32	100	Yes	98.65	98.13	98.13	35min 27s
64	100	Yes	98.96	98.55	98.54	30min 1s

ผลลัพธ์ที่ดีที่สุด คือ ใช้ Batch size 64, 5cv, 100Epochs และ Data Augmentation ให้ค่า Accuracy, Precision, Recall และ Test เป็น 98.96%, 98.55%, 98.54% และ 92% ตามลำดับ

Learning Curve ผลลัพธ์ของการเรียนรู้ (Train) ของ DenseNet121 ที่ดีที่สุดดังภาพ 8




ภาพ 8 Learning Curve ที่ดีที่สุดของ DenseNet121

ผลลัพธ์การทดลองของการทดสอบ (Test) โมเดล DenseNet121 ดังตาราง 6

ตาราง 6 ผลการทดลองค่า Accuracy Test ของ DenseNet121

Batch size	Epochs	Data Augmentation	Time Train	Accuracy Test
-	50	No	21min 40s	55%
32	50	No	17min 4s	65%
-	50	Yes	21min 47s	93%
32	50	Yes	21min 41s	93%
-	100	Yes	37min 39s	92%
32	100	Yes	35min 27s	92%
64	100	Yes	30min 1s	92%

Confusion Matrix ของโมเดลจำแนกประเภทสำหรับ Cassava และ SugarCane โดยโมเดลสามารถทำนาย SugarCane ได้ถูกต้อง 117 ครั้ง และผิดเป็น Cassava 3 ครั้ง ในขณะที่ Cassava ทำนายถูกต้อง 103 ครั้ง และผิดเป็น SugarCane 17 ครั้ง แสดงว่าโมเดลมีความแม่นยำสูงในคลาส SugarCane แต่ยังมีข้อผิดพลาดในคลาส Cassava ดังภาพ 9



ภาพ 9 Confusion Matrix การทดสอบ (Test) ที่ดีที่สุดของ DenseNet121

4.2.4 MobileNetV2


ผลลัพธ์การทดลองของการเรียนรู้ (Train) โมเดล MobileNetV2 ดังตาราง 7

ตาราง 7 ผลการทดลองของ MobileNetV2

Batch size	Epochs	Data Augmentation	Accuracy %	Precision %	Recall %	Time Train
-	50	No	99.90	99.90	99.90	14min 22s
32	50	No	99.90	99.80	99.79	7min 37s
64	50	No	99.90	99.90	99.90	7min 46s
32	100	No	99.69	99.69	99.69	13min 31s
64	100	No	99.69	99.69	99.69	13min 7s
-	50	Yes	98.13	97.83	97.81	7min 42s
32	50	Yes	98.23	97.86	97.81	7min 26s
64	50	Yes	98.02	97.71	97.71	7min 25s
-	100	Yes	98.54	98.46	98.44	12min 45s
32	100	Yes	98.33	97.97	97.92	12min 35s
64	100	Yes	98.44	98.16	98.13	12min 10s

ผลลัพธ์ที่ดีที่สุด คือ ใช้ Batch size 64, 5cv, 100Epochs และ Data Augmentation ให้ค่า Accuracy, Precision, Recall และ Test เป็น 99.69%, 99.69%, 99.69% และ 91% ตามลำดับ

Learning Curve ผลลัพธ์ของการเรียนรู้ (Train) ของ MobileNetV2 ที่ดีที่สุดดังภาพ 10




ภาพ 10 Learning Curve ที่ดีที่สุดของ MobileNetV2

ผลลัพธ์การทดลองของการทดสอบ (Test) โมเดล MobileNetV2 ดังตาราง 8

ตาราง 8 ผลการทดลองค่า Accuracy Test ของ MobileNetV2

Batch size	5CV/EPOCHs	Data Augmentation	Time Train	Accuracy Test
-	Yes/50	No	99.90	92%
32	Yes/50	No	99.79	90%
64	Yes/50	No	99.90	91%
32	Yes/100	No	99.69	90%
64	Yes/100	No	99.69	91%
-	Yes/50	Yes	97.81	93%
32	Yes/50	Yes	97.81	93%
64	Yes/50	Yes	97.71	91%
-	Yes/100	Yes	98.44	90%
32	Yes/100	Yes	97.92	91%
64	Yes/100	Yes	98.13	86%

Confusion Matrix ของโมเดลจำแนกประเภทสำหรับ Cassava และ SugarCane โดยโมเดลสามารถทำนาย SugarCane ได้ถูกต้อง 119 ครั้ง และผิดเป็น Cassava 1 ครั้ง ส่วน Cassava ทำนายถูกต้อง 99 ครั้ง และผิดเป็น SugarCane 21 ครั้ง แสดงว่าโมเดลมีความแม่นยำสูงในคลาส SugarCane และมีข้อผิดพลาดในคลาส Cassava มากกว่าเล็กน้อย โดยรวมประสิทธิภาพของโมเดลยังดี แต่สามารถปรับปรุงในคลาส Cassava ได้เพื่อเพิ่มความแม่นยำดังภาพ 11



ภาพ 11 Confusion Matrix การทดสอบ (Test) ที่ดีที่สุดของ MobileNetV2

5. สรุปผลการวิจัย

จากการทดลองปรับแต่งโมเดลการเรียนรู้เชิงลึกเพื่อการจำแนกพื้นที่เพาะปลูกอ้อยและมันสำปะหลัง ด้วยภาพถ่ายดาวเทียม Sentinel-2 และวัดค่าประสิทธิภาพของโมเดล โดยใช้

โมเดล ResNet50v2, EfficientNetV2B0, DenseNet121 และ MobileNetV2

จากผลลัพธ์การทดลองของโมเดล ResNet50v2 ที่ใช้ Batch size 32, 5CV, 200 Epochs และ Data Augmentation ให้ผลลัพธ์ที่ดีที่สุดด้วยค่า Accuracy 98.23%, Precision 97.82%, Recall 97.81% และ Test Accuracy 95% โดย Learning Curve แสดงความแม่นยำของการฝึกและการตรวจสอบที่คงที่และใกล้เคียงกัน แสดงถึงการเรียนรู้ที่มีประสิทธิภาพ Classification Report และ Confusion Matrix แสดงการจำแนกผิดพลาดน้อยมาก การทดลองชี้ให้เห็นว่าการใช้ Data Augmentation และการตั้งค่าพารามิเตอร์ที่เหมาะสมช่วยเพิ่มประสิทธิภาพโมเดลอย่างมีนัยสำคัญ ทำให้ ResNet50v2 สามารถจำแนกภาพถ่ายดาวเทียม Sentinel-2 ได้อย่างแม่นยำและเชื่อถือได้

จากผลลัพธ์การทดลองของโมเดล EfficientNetV2B0 พบว่าการตั้งค่าที่ให้ผลลัพธ์ที่ดีที่สุดคือ Batch size 32, 100 Epochs พร้อมใช้ Data Augmentation ซึ่งให้ Accuracy (Train) 70.10%, Precision 72.13%, Recall 61.98% และ Accuracy (Test) 68% โดยโมเดลมีประสิทธิภาพสูงในคลาส Cassava ที่ทำนายได้ถูกต้องทั้งหมด 120 ครั้ง แต่ยังมีข้อผิดพลาดสูงในคลาส SugarCane โดยทำนายผิดเป็น Cassava ถึง 76 ครั้ง แม้การใช้ Data Augmentation จะช่วยเพิ่มประสิทธิภาพ แต่ควรปรับสมดุลข้อมูลและพารามิเตอร์เพิ่มเติมเพื่อปรับปรุง Recall ของคลาส SugarCane และเพิ่มความแม่นยำของโมเดลโดยรวม

จากผลลัพธ์การทดลองของโมเดล DenseNet121 พบว่าการตั้งค่าที่ให้ผลลัพธ์ที่ดีที่สุดคือ Batch size 64, 100 Epochs พร้อมใช้ Data Augmentation ซึ่งให้ค่า Accuracy (Train) 98.96%, Precision 98.55%, Recall 98.54% และ Accuracy (Test) 92% โดยโมเดลมีความแม่นยำสูงในคลาส SugarCane ที่ทำนายถูกต้อง 117 ครั้ง และผิดเพียง 3 ครั้ง แต่ยังมีข้อผิดพลาดในคลาส Cassava โดยทำนายผิดเป็น SugarCane ถึง 17 ครั้ง แม้โมเดลจะแสดงผลที่น่าพอใจในภาพรวม แต่ควรปรับปรุงการทำนายคลาส Cassava เพื่อเพิ่มความแม่นยำโดยรวม

จากผลลัพธ์การทดลองของโมเดล MobileNetV2 พบว่าการตั้งค่าที่ให้ผลลัพธ์ที่ดีที่สุดคือ Batch size 64, 100 Epochs พร้อมใช้ Data Augmentation ซึ่งให้ค่า Accuracy (Train) 99.69%, Precision 99.69%, Recall 99.69% และ Accuracy (Test)

91% โดยโมเดลมีความแม่นยำสูงในคลาส SugarCane ที่ทำนายถูกต้อง 119 ครั้งและผิดเพียง 1 ครั้ง แต่ยังมีข้อผิดพลาดในคลาส Cassava โดยทำนายผิดเป็น SugarCane ถึง 21 ครั้ง แม้โมเดลจะมีประสิทธิภาพที่ดีโดยรวม แต่ควรปรับปรุงการทำนายคลาส Cassava เพื่อเพิ่มความแม่นยำ

สรุปผลงานวิจัยได้ว่าการทดลองปรับแต่งโมเดล ResNet50 v2, EfficientNetV2 B0, DenseNet121 และ MobileNetV2 เพื่อจำแนกพื้นที่เพาะปลูกอ้อยและมันสำปะหลังด้วยภาพถ่ายดาวเทียม Sentinel-2 พบว่า MobileNetV2 เป็นโมเดลที่ใช้เวลาฝึก (Training Time) น้อยที่สุดเพียง 7-13 นาทีต่อการตั้งค่าต่างๆ โดยการตั้งค่าที่ให้ผลลัพธ์ที่ดีที่สุดคือ Batch size 64, 100 Epochs พร้อมใช้ Data Augmentation ซึ่งให้ค่า Accuracy (Train) 99.69%, Precision 99.69%, Recall 99.69% และ Test Accuracy 91% แม้จะมีข้อผิดพลาดในคลาส Cassava อยู่บ้าง แต่ MobileNetV2 ยังคงแสดงประสิทธิภาพสูงในคลาส SugarCane และเหมาะสมสำหรับงานที่ต้องการประสิทธิภาพและความเร็วในการฝึกโมเดล

เอกสารอ้างอิง

- [1] กาญจนา ขวัญเมือง, “สศก. ลงพื้นที่ ติดตามสถานการณ์มันสำปะหลังและอ้อยโรงงาน ปี 2566/67 ระบุ ผลผลิตลด เหตุกระทบแล้งและน้ำท่วม ด้านราคา ยังอยู่ในเกณฑ์ดี.”
- [2] Z. Yi, L. Jia, and Q. Chen, “Crop Classification Using Multi-Temporal Sentinel-2 Data in the Shiyang River Basin of China,” *Remote Sens (Basel)*, vol. 12, no. 24, p. 4052, Dec. 2020, doi: 10.3390/rs12244052.
- [3] ทรงกรต พิมพิศาล and ญัฐวุฒิ ศรีวิบูลย์, “การประมวลผลภาพสำหรับการจำแนกรูปภาพพืชโดยใช้การเรียนรู้เชิงลึก,” vol. 10, no. 2, pp. 19–25, Dec. 2563.
- [4] นพรุจ พัฒนสาร and ญัฐวุฒิ ศรีวิบูลย์, “การประมวลผลภาพสำหรับการจำแนกคุณภาพมะม่วงพันธุ์โชคอนันต์ โดยการจำลองการมองเห็นของมนุษย์ด้วยวิธีการเรียนรู้เชิงลึก,” vol. 10, no. 1, pp. 24–29, Jun. 2563.
- [5] Nitika Sharma, “What is MobileNetV2? Features, Architecture, Application and More.” Accessed: Nov. 30, 2024. [Online]. Available: <https://www.analyticsvidhya.com/blog/2023/12/what-is-mobilenetv2/#h-conclusion>
- [6] Pasith Thanapatpisarn, “[Fundamental Data Analytics & Data Scientist EP.20] วัดประสิทธิภาพของโมเดลด้วย Evaluation Metrics Part 1.” Accessed: Nov. 08, 2024. [Online]. Available: <https://datascihaeng.medium.com/evaluation-matrix-part1-ad629e648f8>
- [7] Phakorn, “Learning Curves ที่ใช้ในการวิเคราะห์ประสิทธิภาพ Machine Learning Model.”
- [8] Pagon Gatchalee, “Confusion Matrix เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย ใน Machine learning.”
- [9] ทรัพย์สิน หมื่นรัก, “การพัฒนาทักษะการเขียนโปรแกรมภาษาไพทอนโดยการจัดการเรียนรู้เชิงรุกร่วมกับการสอนทักษะปฏิบัติของแอร์โรว์และแอปพลิเคชันทางการศึกษา สำหรับนักเรียนชั้นมัธยมศึกษาปีที่ 4,” Jun. 2563.
- [10] Shitalkumar R. Sukhdeve and Sandika S. Sukhdeve, “Google Colaboratory.” Accessed: Oct. 29, 2024. [Online]. Available: https://link.springer.com/chapter/10.1007/978-1-4842-9688-2_2